



卢锦鹏

+86 131-1299-2677 · jinplu@mail.ustc.edu.cn · jinplu.github.io



个人简介

主要研究可控视频生成与时空一致性，关注相机交互和分镜变化时，模型如何保持人物身份并持续更新事件状态。曾在北京人形机器人创新中心从事视频世界模型研发，开展相机条件建模与评测，提出 WRBench，同时探索动作条件世界建模与少步动作预测。以第一作者在 ICLR 2026、MICCAI 2024 发表论文，合作成果发表在 EMNLP 2026、MIA 2025 等；相关研究累计获 Google Scholar 引用 163 次，h-index 为 6。

教育背景

中国科学技术大学

硕士，信息与通信工程

合肥

2025.09 至 2028.06 预计

哈尔滨工业大学（深圳）

本科，数据科学与大数据技术，数学类；GPA 3.728/4，综合排名 17/172，前 10%

深圳

2021.09 至 2025.06

实习经历

北京人形机器人创新中心 X-Humanoid, UBTECH

具身智能世界模型算法团队，大模型算法实习生

北京

2025.11 至 2026.10

- 可控视频生成与世界状态评测：独立负责相机可控视频生成，围绕遵循相机轨迹并保持场景动态开展条件注入、模型训练与多源数据构建。通过对照实验分析模型依赖运镜文本而忽略相机条件、运镜时难以保持物体运动等问题，进一步研究视角变化是否影响事件的连续演化；以第一作者提出 WRBench，完成基准设计、自动评分、人工成对评测与论文撰写，揭示相机控制能力的提升并不意味着事件状态能被持续保持。
- 具身世界模型探索：开展动作策略少步采样实验，并定位修复动作条件失效的初始化缺陷；完成初步对照验证。
- 合作研究：参与 VLA-Trace 核心方案设计与完善，成果获 EMNLP 2026 录用；为 Pelican-Unify 1.0 承担数据处理，支持未来视频与动作的联合生成。

主导研究项目

可控视频生成与时空一致性

多镜头叙事视频生成：跨镜头一致性与事件状态演化

2026.05 至 2026.09

- 任务与数据构建：面向人物、场景保持一致且事件随剧本推进的多镜头生成，搭建多源故事数据处理流程，对齐镜头边界与逐镜描述，按视频质量、文字覆盖和内容风险筛选样本；保留分项质量分数与样本权重，形成约 18.4 万故事的训练集，隔离留出评测数据，支持数据配方与模型方法的分别验证。
- 模型设计与迭代：基于 Wan2.2-TI2V-5B，设计故事与实体语义表示和视频潜变量的联合流匹配训练；探索将历史关键帧作为不加噪的潜变量前缀，并用事件后状态描述指导逐镜生成。通过移除语义条件、替换历史关键帧与无记忆对照，区分镜头组织、外观保持和状态更新的作用，检验联合建模与视觉记忆各自能提供什么信息。
- 评测与问题定位：构建剧本驱动的自动评测，将身份保持、镜头切换、物体关系和事件结果拆为可验证问题；用合成错误样例检验视觉语言模型评分，再以故事级重采样估计置信区间。发现外观一致性指标会奖励重复画面，且自生成记忆与前镜文字匹配时容易诱发复制，揭示身份保持与遵循新镜头要求之间的冲突；方法收益仍在验证中。

WRBench：视角变化下的世界状态评测与失效诊断

2026.02 至 2026.07

- 基准与数据设计：针对相机控制和画质评测无法检验事件持续演化的问题，设计相机移开再返回的测试，分别控制目标位移与状态变化；构建场景、首帧和生成指令，统一适配位姿、动作、几何渲染与语言控制，覆盖 25 组场景、23 个模型、9,600 段视频。
- 自动评分与人工验证：结合相机轨迹估计、视觉特征和视觉语言模型问答，分开评测运镜执行、画面完整性及目标可见和重新出现后的状态；以正反问句的回答概率缓解评分偏置，开发网页盲评工具并组织人工成对比较，检验评分与人类判断的一致性，秩相关系数为 0.54 至 0.71。
- 研究发现：运镜方向影响目标移出视野后重新出现的比例，重新出现也不保证位置与状态正确；所评测 Wan-Fun 系列的规模和版本升级主要改善可见阶段的一致性。以第一作者公开 arXiv 预印本，指出相机控制与持续事件状态建模之间的能力差距。

- **数据处理**：面向给定轨迹的相机控制，整合多源自然与具身视频，使用 ViPE 补全相机位姿，统一坐标、轨迹尺度和帧率；实现异常轨迹筛选、运动分布统计与采样，并清理文本中的运镜描述，减少模型绕过相机条件的文本捷径。
- **条件建模与训练**：在 Wan2.2-TI2V-5B 上实现逐像素 Plücker 射线与相对相机位姿条件，分别从输入端和网络各层注入；借鉴 ReCamMaster 的位姿编码，在图生视频设置下开展冻结主干、全参数微调与混合数据训练，分析轨迹跟随和场景动态保持。
- **实验诊断**：在具身场景中观察到仿真训练的模型能跟随相机却难以保持机械臂动作，加入真实具身数据后动态改善而控制减弱；结合文本与位姿对照、轨迹可视化分析失效，将运镜与事件演化的耦合问题发展为 WRBench。

高效视觉表征与多模态融合

- **高效结构设计**：针对轻量三维分割丢失细节、跨模态交互开销高的问题，以 Johnson-Lindenstrauss 引理指导分组卷积的通道数，设计成对窗口注意力并行建模多尺度局部与远距离联系，实现卷积与注意力互补的多模态网络，构建 1.66M 参数网络。
- **知识迁移与消融**：用通道 Gram 矩阵匹配教师与学生的特征相关性，将自监督重建的纹理知识迁移到分割网络，避免两类任务关注区域不同导致的空间对齐问题；通过结构、分组尺度与蒸馏消融区分容量压缩、模态交互和纹理监督的作用，使知识迁移仅发生在训练阶段。成果以第一作者获 ICLR 2026 录用。

发表成果：一作与共同一作

ICLR 2026 CCF-A	Johnson-Lindenstrauss Lemma Guided Network for Efficient 3D Medical Segmentation Citations: 1 Jinpeng Lu , Linghan Cai, Yinda Chen, Guo Tang, Songhan Jiang, Haoyuan Shi, Zhiwei Xiong 针对轻量模型丢失局部细节的问题，联合设计分组卷积、多尺度跨模态注意力和纹理蒸馏。在 AutoPET-II 消融中，蒸馏将同结构模型的 Dice 从 59.71% 提升至 62.51%，参数量保持 1.66M，推理开销不变。
arXiv 2026	Current World Models Lack a Persistent State Core Citations: 7 HF votes: 18 Jinpeng Lu , Dexu Zhu, Haoyuan Shi, Linghan Cai, Guo Tang, Yinda Chen, Jie Cao, Duyu Tang, Yi Zhang, Yong Dai, Xiaozhu Ju 提出以相机运动干预观察的世界状态诊断基准，区分运镜失败、再观察证据不足和事件状态错误。对 23 个模型的评测揭示，相机控制与画面一致性的进步未必带来持续的事件状态建模能力。
arXiv 2025	Does DINOv3 Set a New Medical Vision Standard? Citations: 54 HF votes: 40 Che Liu*, Yinda Chen*, Haoyuan Shi*, Jinpeng Lu* , et al. 系统评测自然图像自监督特征向医学分类与三维分割的迁移。发现增大模型和输入分辨率并不持续改善医学任务表现，病理、电子显微与 PET 等模态仍有明显局限，为视觉基础模型的跨领域选型提供依据。
MICCAI 2024 CCF-B Early Accept	H2ASeg: Hierarchical Adaptive Interaction and Weighting Network for Tumor Segmentation in PET/CT Images Citations: 18 Jinpeng Lu , Jingyun Chen, Linghan Cai, Songhan Jiang, Yongbing Zhang 针对 PET 与 CT 独立编码难以充分交换互补信息的问题，设计局部与全局的双向跨模态注意力，并以肿瘤感知权重细化边界。论文在 AutoPET-II 与 Hecktor2022 上优于所比较方法，验证分层交互对多模态肿瘤分割的作用。

学术服务与技能

学术服务	ICLR 2027、NeurIPS 2027、IEEE TNNLS 审稿人。
生成建模	视频扩散与流匹配、相机位姿条件、参考帧记忆、语义与视频联合建模；能通过条件消融区分控制信号与文本、历史画面的影响。
实验与评测	干预式基准设计、视觉语言模型评分、人工成对盲评与重采样统计；关注指标是否区分外观相似、指令遵循和事件状态正确。
数据与实现	多源视频质量筛选、镜头与描述对齐、相机轨迹处理和训练评测隔离；技术实践包括 Python、PyTorch、DeepSpeed ZeRO 与多机多卡全参数微调。