

卢锦鹏

求职意向：视频生成算法研究实习

jinplu@mail.ustc.edu.cn · jinplu.github.io · Scholar · GitHub

中科大硕士，预计 2028.06 毕业 · 即刻到岗，全职 6 个月以上 · 北京/上海/杭州



个人简介

研究方向为可控视频生成与具身世界模型，关注视频模型能否在视角与镜头变化下维持一致的世界状态。基于 Wan2.2 设计并训练相机轨迹控制与多镜头视频生成模型，熟悉 DiT、流匹配与分布式训练；构建多源相机轨迹视频数据流水线；以第一作者提出持久事件状态评测基准 **WRBench** (23 个模型、9,600 段视频)，搭建视觉语言模型自动打分与人工评测体系；另有 **ICLR 2026**、**MICCAI 2024** 第一作者论文。

教育背景

中国科学技术大学

硕士，信息与通信工程；导师：熊志伟

合肥

2025.09 – 2028.06 (预计)

哈尔滨工业大学（深圳）

本科，数据科学与大数据技术（数学类）；GPA 3.728/4，综合排名 17/172（前 10%）

深圳

2021.09 – 2025.06

实习经历

北京人形机器人创新中心（X-Humanoid, UBTECH）

具身智能世界模型算法团队，大模型算法实习生

北京

2025.11 – 2026.09

- 独立负责相机可控视频生成与动作策略少步采样两项研究，覆盖方法设计、模型训练与评测；在基于 Cosmos3-Edge 的动作策略上，1 步采样的 LIBERO-10 成功率不劣于 30 步（三次各 500 回合，95–96% 对约 93%），服务端延迟中位数由 697 ms 降至 141 ms。
- 针对相机运动可能改变生成事件的问题，以第一作者提出 **WRBench**，完成基准设计、评测系统开发与论文撰写。
- 定位开源 Cosmos-Predict2.5 动作编码层在权重初始化之后才构建、参数全零的静默缺陷（四种动作输入的输出逐比特相同），修复后恢复动作响应；为动作条件视频模型建立含零/反向/打乱动作对照、bootstrap 置信区间与指标下限审计的可控性评测，并完成视频基座的评测与选型。
- 具身智能合作研究：参与 **VLA-Trace** 核心方案设计与完善（EMNLP 2026）；在 **Pelican-Unify 1.0** 中主要承担数据处理，支持未来视频与动作的联合生成。

研究经历

相机可控视频生成：面向具身世界模型的轨迹控制

2025.12 – 2026.03

- 问题与动机：具身世界模型需要在机器人转头、移动时生成新视角，并在视角移开再返回后保持场景与事件一致；但具身数据几乎都是固定机位、缺少位姿，通用相机控制方法迁移时，模型倾向依赖文本或训练样本而非相机条件，相机运动还会破坏机械臂动态。
- 方法：在 Wan2.2-TI2V-5B 上系统比较两类相机条件：输入端 Plücker 射线经卷积适配器注入（CameraCtrl 式）与逐层相对位姿注入（ReCamMaster 式），并对比分阶段训练、冻结主干与全量微调；针对文本捷径，用大语言模型清洗约 270 万条描述中的运镜信息。
- 数据：构建多源相机轨迹数据流水线（MultiCamVideo、SpatialVID、DynPose、RealEstate10K 等），统一坐标系、内参与帧率，修复稀疏位姿插值缺陷（SLERP），用 ViPE 补全无位姿视频，按运动分布均衡采样；诊断出 SpatialVID 约 99% 为前进运动等偏差，并制定手机 LiDAR 自采规范。
- 发现：(1) 描述中的运镜词与位姿泄露会形成文本捷径，使相机条件失效；(2) 相机可控性与具身动态存在权衡：仅用合成多机位数据时控制强但机械臂动态丢失，混入具身数据后动态保持而控制明显减弱；(3) 多源混训并非单调有益，不同数据分别导致抖动、跟随文本、跟随采集轨迹三类失效；(4) “画面动了”不能说明事件被正确保持，由此转向 **WRBench**。

WRBench：视频世界模型的持久事件状态评测

2026.02 – 2026.07

- 问题与动机：视频生成模型常被称作世界模型，但画面可信不等于世界在持续演化：相机运动应只改变观察、不改变事件，事件在不可见时也应继续演化。现有评测覆盖画质、物理合理性与相机可控性，却不检验观察改变时模型是否维持同一个演化中的世界。
- 方法：将相机运动建模为只改变观察的相机干预，让目标经历“可见—移出视野—重新出现”；以空间位移 × 状态变化的 2×2 事件设计覆盖 25 组场景，分阶段评测相机执行、可见阶段一致性、再观察支持度与再观察终态正确性，区分

“没再看到”与“看到但状态错误”；把同一干预统一翻译为相机参数、动作、几何缓存与文本四类原生接口。

- **评测系统**：搭建“大语言模型场景分类—文生图首帧—图生视频提示”的数据生成流程并做防泄露校验；设计视觉语言模型打分器（yes/no 词元概率、正反子问题去偏），结合 VGGT- Ω 相机执行与 DINOv2 视觉完整性评测；制定单视频评分与双视频盲评协议，开发网页标注工具，用 4,100 余条人工判断检验评测器（Spearman ρ 0.54–0.71）。
- **发现**：覆盖 **23 个模型、9,600 段视频**：（1）相机变化会泄漏进事件演化，仅改变转向方向即可使再观察支持度变化 17.8–51.3 个百分点；（2）状态变化使可见空间一致性下降 13.0 分，所有配置均为负；（3）最易被再观察的模型并不在终态正确性上领先；（4）规模与版本升级主要提升“看得见”而非“状态持久”。据此提出持久事件状态应作为独立的评测与训练目标。

多镜头视频生成：跨镜头的实体保持与状态更新

2026.05 – 2026.09

- **问题与动机**：多镜头叙事要求同时“保持”与“更新”：已出现的人物与场景需在后续镜头中保持，机位、动作与事件状态需按剧本改变（如前镜摘下的帽子不应再出现）。联合生成受窗口长度限制，逐镜续写在硬切后易出现身份衰减与状态回退。
- **方法**：在 Wan2.2-TI2V-5B 上探索两条路线：故事与实体语义 token 与视频潜变量联合去噪（**语义—视频联合流匹配**），让保持与更新共享同一优化目标；以及把前镜关键帧作为干净潜变量前缀经原生首帧通道注入的参考帧记忆（借鉴 StoryMem 的负 RoPE 位移），并以事件后的 Keep/Change 状态描述作为条件。
- **评测与数据**：构建 18.4 万故事的多镜头训练数据（质量打分与镜界标注），完成全参训练；设计由剧本编译断言的状态评测基准（100 条全硬切剧本、2,000 余条断言），先以合成坏例验证评测器，再以按故事整簇 bootstrap 置信区间与预注册门控判定结果。
- **诊断发现**：受控探针表明，参考帧记忆在“自生成记忆且文字吻合”时显著触发前镜内容带入（相对无记忆对照 +29.5 个百分点，置信区间不含 0）；常用跨镜一致性指标会奖励照抄与不切镜（真实视频得分低于多数生成结果），因此改用剧本断言评测。研究进行中。

发表成果

ICLR 2026 CCF-A	Johnson-Lindenstrauss Lemma Guided Network for Efficient 3D Medical Segmentation Jinpeng Lu , Linghan Cai, Yinda Chen, Guo Tang, Songhan Jiang, Haoyuan Shi, Zhiwei Xiong 提出 JL 引理指导的分组卷积与 Paired Window Attention，并以通道 Gram 矩阵迁移自监督教师的纹理知识，构建 1.66M 参数的 VeloxSeg。
arXiv 2026 WRBench	Current World Models Lack a Persistent State Core Jinpeng Lu , Dexu Zhu, Haoyuan Shi, Linghan Cai, Guo Tang, Yinda Chen, Jie Cao, Duyu Tang, Yi Zhang, Yong Dai, Xiaozhu Ju 提出持久事件状态评测基准 WRBench，发现现有视频模型在“渲染与重访世界”上的进步快于“维持演化中的事件状态”。
Tech Report 2025 共同一作	Does DINOv3 Set a New Medical Vision Standard? Che Liu, Yinda Chen, Haoyuan Shi, Jinpeng Lu , et al. 系统评估自然图像预训练模型在医学二维／三维任务上的迁移能力与局限。
MICCAI 2024 CCF-B Early Accept	H2ASeg: Hierarchical Adaptive Interaction and Weighting Network for Tumor Segmentation in PET/CT Images Jinpeng Lu , Jingyun Chen, Linghan Cai, Songhan Jiang, Yongbing Zhang 设计跨窗口模态协同注意力与目标感知模态加权，融合 PET 代谢与 CT 解剖信息。

学术服务与技能

学术服务	ICLR 2027、NeurIPS 2026、IEEE TNNLS 审稿人。
生成与控制	DiT、流匹配、视频扩散模型微调（Wan2.2）、相机条件注入（Plücker 射线、相对位姿）、参考帧条件、视频与语义联合建模、知识蒸馏。
数据与评测	多源视频数据构建、相机位姿估计（ViPE、VGGT）、坐标与轨迹规范化、大语言模型批量清洗描述；视觉语言模型自动打分、人工评测协议与标注工具、置信区间与配对统计检验。
训练与工程	Python、PyTorch、DeepSpeed ZeRO、多机多卡分布式训练与全参数微调、断点续训、推理性能分析。